
AI Water 智慧水务技术报告

南哪战队

2025-12-20

Contents

1 研究背景 3

2 方法论 4

2.1 Squeeze (压缩): 获得全局通道统计信息 5

2.2 Excitation (激励): 学习通道权重 5

2.3 Scale (重标定): 将权重作用到通道上 6

3 实验设计 7

3.1 数据集 7

3.2 基线方法 7

3.3 实施细节 8

4 模型训练 8

5 测试评估 8

6 创新点 9

6.1 超轻量通道注意力机制以显式建模通道依赖关系 9

6.2 面向声学漏水特性的动态特征重标定策略 10

6.3 即插即用的轻量增强模块设计 10

7 应用价值 10

7.1 提升城市供水管道的主动监测能力 10

7.2 实现早期、精准的漏水识别, 显著减少水资源浪费 11

7.3 轻量化设计适配边缘部署, 降低工程实施成本 11

8 部署形式 11

8.1 项目概述 11

8.1.1 主要功能 12

8.2	技术架构	12
8.2.1	前端技术栈	12
8.2.2	后端技术栈	12
8.2.3	AI 模型依赖	13
8.3	环境要求	13
8.3.1	基础环境	13
8.3.2	Python 环境配置	14
8.4	部署形式	14
9	实用工具	15
9.0.1	自动化构建脚本	15
9.0.2	运维脚本	15
10	难点突破	15

1 研究背景

城市供水管道的漏水问题长期以来是全世界供水系统面临的关键挑战之一。漏水不仅导致水资源的巨大浪费，还造成管道能耗增加、设备负荷加重、运营成本提升，并进一步可能引发地面塌陷、结构破坏及二次灾害。为减少损失，实现对漏水的早期、高精度识别与定位已成为城市智慧水务建设中的核心需求。现有管道泄漏检测技术大体可分为三类：一类基于水力模型与压力/流量分析，通过压力波形异常、最小夜流变化等指标判断泄漏，但其对噪声敏感且难以检测微小泄漏；第二类基于气体、化学示踪物或视觉检测，但通常成本较高且难以用于埋地管道；第三类为近年来最受关注的声学方法与声学发射检测方法，其在无需破坏管道的情况下即可实现连续监测，并能对早期泄漏保持较高敏感度。

在本文的技术报告中，我们主要关注第三类基于声学的检测方法。声学方法的基本原理是：水管一旦漏水，水会从破洞里喷出来。因为管子里水压很高，这股“喷出去”的水会发出一种嘶嘶的声音，就像气球漏气或水龙头有缝隙时的声音一样。这个声音会顺着水管传播，我们把小型“麦克风”贴在管道附近（比如阀门、地面、接头处），就能把这些漏水发出的声音记录下来，从而判断哪里可能有漏点。大量研究指出，声学方法在实际工程中具有较强的鲁棒性和实用性，尤其适用于夜间低背景噪声的城市供水网络。然而，由于泄漏声的传播会受到管材、地下掩埋深度、土壤类型、路面结构、流速变化等多个因素影响，使得信号呈现低信噪比、非平稳、易被环境噪声淹没等特点，这对泄漏识别算法提出了更高要求。

为解决上述挑战，研究者在信号处理和机器学习方面开展了大量工作。Feng 等人提出了一种针对供水管道微泄漏声学检测的改进方法，通过构建管道模型并采用 FW-H 方程模拟泄漏声波的产生与传播，重点分析了低压、小孔径泄漏的声学特性；为克服环境干扰，该方法结合经验模态分解提取泄漏声信号，并利用互相关时延估计法对 T 型管件附近泄漏点进行定位。Boadu 等人提出了一种基于无线噪声记录仪的创新漏水检测模型，通过分析香港供水管道中的真实声学数据，结合傅里叶变换进行信号处理，并采用集成学习算法整合卷积神经网络、朴素贝叶斯和支持向量机等分类器的优势，有效降低了误报率。Shin 等人提出了一种基于 LSTM 与自动编码器相结合的框架，用于检测水管泄漏。该框架旨在处理时间序列数据的时序维度，并集成集成学习技

术，从而能够灵敏地识别微小的泄漏信号，同时有效抑制噪声干扰。通过结合信号处理与模式识别技术，这一基于机器学习的方法为解决泄漏检测问题提供了一个智能系统。Gunatilake 等人提出了一种名为多类时频卷积神经网络（M-TFCNN）的新型神经网络模型，该模型通过精心设计的特征提取模块、卷积基和分类头，能够对实时城市地下水管中的泄漏事件进行精细分类，识别出如管道破裂、消防栓泄漏、阀门泄漏等不同泄漏的具体性质，从而超越了传统方法仅能检测泄漏是否存在的局限。除此之外，其他一些研究也使用时域特征（RMS、峰值、峭度）、频域特征（谱峰值、带宽、峰度）、时频特征（STFT、梅尔频谱、CWT）、能量分析等声学特征提取方法。

总体而言，水管漏水声音检测技术正逐步从传统经验驱动方法向自动化、智能化方向发展，融合声学信号处理、机器学习、深度学习以及多传感器融合等跨学科技术，逐渐成为智慧水务的重要组成部分。尽管仍面临环境噪声干扰、模型跨场景迁移困难以及实时部署约束等挑战，但声学方法在早期检测能力、部署便利性和成本可控性方面具有明显优势，是未来城市管道主动控制与智能运维的关键研究方向。

2 方法论

我们在 AI Water 智慧水务项目中引入了注意力机制，以解决传统卷积神经网络无法处理多通道输入的问题。核心思想是通过一个极其轻量却表达力很强的注意力机制，让神经网络能够显式地建模通道之间的依赖关系，使网络根据输入自适应地重新为每个通道分配权重，从而突出关键特征、抑制无效通道。传统卷积过程主要在空间维度进行局部计算，而不同通道之间的关系是隐式的、无法动态调整的。我们的方法首次让网络能够“按需选择特征通道”，实现“重要的放大、不重要的削弱”，并在几乎不增加计算量的前提下显著提升性能。

整个方法由三个阶段组成：Squeeze（压缩）和 Excitation（激励），随后进行 Scale（重标定）操作。

2.1 Squeeze (压缩): 获得全局通道统计信息

在 Squeeze 阶段, 我们的方法通过全局平均池化 (Global Average Pooling) 获取每个通道的全局语义统计量。若输入特征为

$$U = [u_1, u_2, \dots, u_C], u_c \in \mathbb{R}^{(H \times W)}$$

我们对每个通道求平均, 得到一个描述整张图中该通道激活程度的标量

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j)$$

从而获得长度为 C 的全局描述向量

$$\mathbf{z} = [z_1, z_2, \dots, z_C]^T$$

这一过程等价于“压缩”通道特征, 使其从空间维度 ($H \times W$) 降至通道维度 (C), 让每个通道都拥有代表其全局贡献的数值, 而无需任何额外空间计算。目的是让网络获得图像的全局语义, 不再只依赖局部卷积。

2.2 Excitation (激励): 学习通道权重

这是一个小型的 MLP (两层全连接)。在 AI Water 智慧水务项目中, 我们建立了一个轻量的两层全连接网络来学习通道之间的复杂关系, 从而生成每个通道的注意力权重。具体而言, 我们首先利用一个全连接层将通道数从 C 降维到 C/r :

$$e = \delta(W_1 z)$$

其中 $W_1 \in \mathbb{R}^{\frac{C}{r} \times C}$, r 为缩放比例 (在本项目中我们取了 16), δ 为 ReLU 激活函数。通过这种做法, 我们可以降低参数量, 同时让网络在一个更紧凑的语义空间中捕获

通道之间的依赖信息。随后使用第二个全连接层将维度从 C/r 升维回 C :

$$s = \sigma(W_2 e)$$

其中 $W_2 \in \mathbb{R}^{C \times \frac{C}{r}}$, σ 为 Sigmoid 函数, 用于生成范围在 $(0, 1)$ 内的通道注意力权重。综合以上两个公式可以描述为:

$$s = \sigma(W_2 \delta(W_1 z))$$

得到权重向量 $\mathbf{s} \in \mathbb{R}^C$ 。

$$s = [s_1, s_2, \dots, s_C]^T$$

生成的每个 s_c 代表通道 c 的重要性, 数值越大, 当前输入中该通道越关键。

2.3 Scale (重标定): 将权重作用到通道上

目标是发挥通道注意力机制的本质: 让网络知道“哪个通道重要”并自动调节。我们的方法将权重 s_c 应用于对应的特征图通道, 进行逐通道加权:

$$\tilde{\mathbf{u}}_c = s_c \cdot \mathbf{u}_c$$

将所有加权后的通道重新组合即可得到增强后的输出特征:

$$\tilde{\mathbf{U}} = [\tilde{\mathbf{u}}_1, \tilde{\mathbf{u}}_2, \dots, \tilde{\mathbf{u}}_C]$$

通过这种机制, AI Water 智慧水务中的神经网络可以动态、输入自适应地选择最有用的通道特征, 实现“重要通道增强、不重要通道抑制”。这相当于赋予网络一种内容驱动的注意力能力, 从而大幅提升整体表示能力, 而额外计算成本极小。

以上三个步骤的模块就是一个轻量级的通道注意力模块。首先我们用全局池化提取全局语义，接着我们用两层全连接学习通道权重，最后我们重新标定卷积特征。

3 实验设计

3.1 数据集

我们首先从上万条原始人工采集的管道漏水音频数据中筛选出约两千条左右质量较高的样本，并将其按照风险等级划分为三类：高风险、低风险和无风险。随后，我们按照 9:1 的比例构建训练集和验证集，三类数据在训练与验证阶段的总体规模分别为：高风险 420 条、低风险 518 条、无风险 462 条。此外，我们保留了一部分未参与训练的独立测试集，用于评估模型的泛化性能，其中包含：高风险 64 条、低风险 79 条、无风险 70 条数据。整个数据集的划分充分保证了类别分布的合理性和测试阶段的独立性，有助于对模型性能进行全面、可靠的评估。

3.2 基线方法

CAMPPlus: 该方法以密集连接时延神经网络 (D-TDNN) 为骨干，通过在每个 D-TDNN 层中嵌入轻量化的上下文感知掩码 (CAM) 模块来聚焦目标音频特征，并采用多粒度池化融合全局和局部的上下文信息以生成更精准的注意力权重。

TDNN: 该方法是一种基于自动语音识别 (ASR) 的语音清晰度预测模型，该模型利用深度神经网络 (DNN) 输出的音素后验概率，通过平均时间距离 (MTD，即 M 测度) 量化其退化程度，从而直接估计词错误率 (WER) 并预测语音接收阈值，无需在测试时依赖干净语音参考或文本标签。

ERes2Net: 该方法是一个增强型 Res2Net 架构，通过局部特征融合和全局特征融合来改进说话人验证。局部特征融合使用注意力特征融合模块在残差块内增强相邻特征图间的局部信息交互，而全局特征融合则在网络底部向上路径中聚合不同时间尺度的多尺度特征以获取全局信息。

3.3 实施细节

我们将方法论中的三个步骤作为一个可插拔的模块嵌入到现有 ResNet 中，并对卷积层的输出进行增强。它并不会取代卷积，而是作为卷积后的一个“增强步骤”，帮助网络自动选择重要通道，提高整体特征质量。

4 模型训练

在 AI Water 智慧水务项目中，所有训练的超参数均通过配置文件统一管理。我们首先对原始音频进行预处理，包括按 16kHz 采样率读取、音量归一化等操作，并使用 80 维 Fbank 声学特征作为模型输入，以获得稳定且高效的时频表示。数据通过训练、验证与测试列表文件进行组织，并按批量大小 32（训练）与 4（验证/测试）加载进入模型。整个数据处理流程可支持数据增强、音频裁剪与归一化等功能，从而提升模型在不同场景下的泛化能力。

训练过程中使用 Adam 优化器，并结合 Warmup + Cosine Decay 学习率策略以稳定模型收敛。所有训练流程由 train.py¹完成，包括配置读取、模型构建、断点恢复、预训练模型加载、VisualDL 日志记录等功能。最终模型在 60 个 epoch 内完成训练，并自动保存至指定路径，确保训练过程可复现、可扩展。

5 测试评估

模型名	准确率 (%)
CAMPPlus	0.9172
TDNN	0.9236

¹详见项目开源地址的/model/train.py

模型名	准确率 (%)
ERes2Nete	0.9375
AI Water 智慧水务复合模型	0.9514

在实验评估中，我们可以看出 AI Water 智慧水务中使用的复合模型达到了 95.14% 的准确率，显著优于其他基线模型。与表现次优的 ERes2Net（93.75%）相比，AI Water 智慧水务模型将准确率提升了 1.39 个百分点。这一性能提升得益于其创新的超轻量通道注意力机制，该机制通过动态建模通道依赖关系，有效增强了泄漏声关键特征的表达能力，同时在低信噪比环境下展现出更强的鲁棒性。值得注意的是，这些优势的取得仅带来了极小的计算开销，使模型特别适合在资源受限的边缘设备上部署，为智慧水务系统中的实时漏水检测提供了可行的技术方案。

6 创新点

我们在 AI Water 智慧水务中使用的复合模型在声学管道漏水检测任务中实现了高效、轻量且鲁棒的特征增强能力，相较于传统方法在通道特征建模、计算效率以及跨场景泛化等方面具有显著优势。核心创新点如下：

6.1 超轻量通道注意力机制以显式建模通道依赖关系

传统卷积神经网络只能隐式处理通道之间的相关性，而无法根据输入内容动态调整每个通道的重要程度。本研究首次将极轻量的通道注意力结构引入管道漏水声音识别任务，通过三阶段机制显式建模通道依赖关系，使模型能够“按需选择”最关键的声学特征通道。该设计在不改变主干网络（本研究使用 ResNet 作为主干网络）的前提下显著提升了特征表达能力，且仅带来极小的参数与计算开销，特别适合实际智慧水务部署中的低算力设备。

6.2 面向声学漏水特性的动态特征重标定策略

基于泄漏声信号的非平稳性、低信噪比以及受环境干扰强等特点，本研究通过全局语义压缩与两层瓶颈式 MLP 生成通道权重，使模型能够重点关注稳定的泄漏声模式（如喷射噪声、涡流噪声）并抑制随机环境噪声。相比传统仅依赖时间域或频域手工特征的方法，动态重标定策略能够根据不同管道材质、埋深与背景噪声自适应调整权重，显著提升跨场景鲁棒性。

6.3 即插即用的轻量增强模块设计

与已有的复杂深度结构不同，AI Water 智慧水务中的注意力模块具有极高的通用性，可无缝插入 ResNet 模型中作为增强组件，而不改变其前后层结构。这种模块化设计既能够补强现有声学模型的特征学习能力，也便于在工业管道监测系统中快速移植、升级与迭代。

7 应用价值

本次我们使用的 AI Water 智慧水务漏水检测方法在智慧水务建设、城市基础设施安全保障及行业实际部署方面具有显著的应用价值。其高效、轻量、鲁棒的特征建模能力，使其在多种复杂场景下均能提供稳定且可扩展的漏水诊断能力，为城市供水系统的智能化升级提供了可行路径。其应用价值主要体现在以下三个方面：

7.1 提升城市供水管道的主动监测能力

传统漏水检测方式多依赖人工巡检或现场听音，效率低、成本高且难以及时发现隐蔽性或早期泄漏。AI Water 智慧水务基于声学数据自动识别管道异常信号，可实现对管道的全天候、连续化、非侵入式监测，弥补了人工检测的延迟性与不连续性，使供水企业从“被动响应”向“主动预警”转变。

7.2 实现早期、精准的漏水识别，显著减少水资源浪费

泄漏初期往往声强较弱、信号易被噪声淹没，是传统方法的检测盲区。AI Water 智慧水务通过通道注意力增强泄漏声的关键特征，在低信噪比场景下仍能保持稳定识别性能，有助于在泄漏扩展之前及时发现异常。该能力可显著减少水资源浪费、降低能耗损失、避免管道破裂等重大次生风险，直接提升城市供水系统的运行效率与安全性。

7.3 轻量化设计适配边缘部署，降低工程实施成本

与许多深度学习算法对计算资源的高依赖不同，AI Water 智慧水务的结构设计极其轻量，参数量与计算量均远低于同类复杂模型，可在低功耗边缘设备、井盖节点、阀门监测器或智能传感终端上实时运行。这意味着无需昂贵 GPU，也无需大规模通信带宽，即可构建分布式漏水监测网络，从而显著降低部署成本和运维难度。

8 部署形式

我们基于 Vue3 + Element Plus 构建了智慧水务 AI Water 漏水音频识别后台管理系统，用于管理和分析上传的音频文件，及时发现漏水点，解放人类手动检测的耗时和误差。系统使用深度学习模型对音频进行分类和风险评估。

8.1 项目概述

这是一个前后端分离的管理系统，采用现代化技术栈：

- 前端：Vue3 + Element Plus + Vite 构建响应式用户界面
- 后端：Node.js + Express 提供 RESTful API 服务
- AI 模型：Python + PyTorch 进行音频分类识别

8.1.1 主要功能

- 用户认证和权限管理
- 音频文件上传和管理
- 基于 AI 模型的音频风险评估
- 数据可视化展示（仪表板、趋势分析）
- 系统初始化和管理员设置
- 音频记录查询和历史分析

8.2 技术架构

8.2.1 前端技术栈

技术	说明
Vue 3	渐进式 JavaScript 框架
Element Plus	基于 Vue 3 的组件库
Vue Router	路由管理
Axios	HTTP 客户端
ECharts	数据可视化库
Vite	构建工具

8.2.2 后端技术栈

技术	说明
Node.js	JavaScript 运行时环境
Express	Web 应用框架
SQLite	轻量级数据库
BCrypt	密码加密库
JWT	JSON Web Token 认证
Multer	文件上传中间件
Python Shell	Python 脚本执行

8.2.3 AI 模型依赖

库	说明
PyTorch	深度学习框架
macls	音频分类库
torchaudio	音频处理库
numpy / scipy	科学计算库

8.3 环境要求

8.3.1 基础环境

- **Node.js** $\geq 18.x$ (推荐使用 LTS 版本)
- **Python** ≥ 3.8

- **npm** $\geq 9.x$
- **Docker** ≥ 18.09 (可选, 用于容器化部署)
- **Git** ≥ 2.0

8.3.2 Python 环境配置

```
1 pip install torch torchvision torchaudio
2 git clone https://github.com/yeyupiaoling/
  AudioClassification-Pytorch.git
3 cd AudioClassification-Pytorch/
4 pip install .
```

8.4 部署形式

为了方便项目快速启动,我们将其打包为 Docker 镜像,并使用 Docker Compose 快速启动。通过区分架构的部署脚本,我们实现了在 AMD64 架构和 RISC-V 架构下一键启动的快速部署方式。

```
1 #AMD64 架构
2 curl -sSL https://raw.githubusercontent.com/Lvshujun0918/
  AI_Water/refs/heads/main/install.sh | bash
3
4 #RISC-V 架构
5 curl -sSL https://raw.githubusercontent.com/Lvshujun0918/
  AI_Water/refs/heads/main/install-riscv.sh | bash
```

同时,我们当然也支持源码安装。如下展示了常见的克隆、安装依赖、启动的步骤:

```
1 git clone https://github.com/Lvshujun0918/AI_Water
2 cd AI_Water
3 npm install
4 cd frontend && npm install && cd ..
5 cd backend && npm install && cd ..
6 npm run dev
7 # 后 端 服 务 (http://localhost:3000)
8 # 前 端 服 务 (http://localhost:8080)
```

考虑到 AI Water 智慧水务项目初期的容积较小，我们通过文件直传和 Sqlite 的形式储存相关数据，并通过 Docker 卷实现数据持久化：

```
1 backend/uploads      → 用户上传的音频文件存储
2 backend/users.db     → SQLite 数据库（用户、记录等）
```

9 实用工具

9.0.1 自动化构建脚本

为了方便 AI Water 智慧水务项目在实际工程中的镜像修改和构建。我们在项目中提供了专用于 RISC-V 64 位设备的自动化构建脚本 `build-and-push.sh`，可将 Docker 镜像直接推送到 GitHub Container Registry (GHCR)。

通过该脚本，我们实现了前后端依赖安装、构建、打包的自动化操作，同时可以将镜像上传到云端，方便多端的快速同步和运行。

9.0.2 运维脚本

考虑到 RISC-V 开发板在实际工程中常常被部署在管网处，工程师难以接近。为了方便 AI Water 智慧水务项目的端侧开发板进行控制调试，我们提供了自动化的穿透脚本 `frps.sh`，可一键将开发板的服务端口映射到远端服务器，极大地方便了工程师进行调试。

10 难点突破

在 AI Water 智慧水务项目从开发环境向实际部署环境迁移的过程中，RISC-V 环境依赖问题成为影响系统稳定性与可复现性的关键难点之一。该类问题并不直接体现在

算法或模型本身的设计复杂度上，而是源于运行环境、依赖组件与底层系统之间高度耦合所带来的隐性不确定性。

对于 AI Water 智慧水务项目必需的 PyTorch 框架，其本身包含大量依赖于底层计算与自动求导机制的原生模块，其运行高度依赖于编译阶段对目标架构的精确适配。在 RISC-V 平台上，由于相关工具链和预编译生态尚处于发展阶段，框架及其扩展组件往往需要针对架构特性进行定制化构建。不同构建环境之间在功能启用范围和内部接口实现上的差异，使得部署过程对环境一致性的要求显著提高。

我们通过 Dockerfile 的优化，成功实现了基于 PyTorch 的模型在 RISC-V 架构环境下的稳定部署。具体而言，在容器构建过程中对基础镜像、依赖安装顺序以及框架组件来源进行了精细化控制，避免了不同构建体系混合使用所带来的不确定性。通过在镜像构建阶段明确限定 PyTorch 及其相关扩展组件的获取方式，使其统一来源于同一编译环境，从而保证了核心框架与扩展模块在二进制层面的兼容性。

同时，在 Dockerfile 中对系统级依赖和 Python 运行环境进行了前置配置，确保底层工具链、动态链接库及运行时环境在容器构建阶段即完成验证，而非在运行阶段动态加载。这种方式有效降低了由于 RISC-V 平台系统环境差异所引入的运行时风险，提高了部署结果的可复现性和可移植性。此外，通过合理划分镜像构建层次，将与架构强相关的依赖固定在基础层中，减少了后续应用层变更对底层运行环境的影响。